

Proyecto Integrador - Minería de Datos I

Analisis de Factores de Costo en Seguros Medicos

Modulo 3: Modelar y Comunicar | Javier Molina - Federico Claramunt

1. Contexto y objetivo

Este proyecto analiza los factores que influyen en el costo del seguro medico utilizando un dataset de 1,363 asegurados con 7 variables: edad, sexo, IMC, numero de hijos, condicion de fumador, region y costo del seguro. El objetivo es identificar los principales determinantes del costo mediante EDA, PCA y visualizacion interactiva con Streamlit.

2. Dataset y calidad inicial

El dataset original contenia 152 valores nulos (102 en age, 50 en bmi) y multiples inconsistencias: sex y smoker con 4 variantes cada una por diferencias de capitalizacion, region con 8 variantes por mezcla de siglas (SE, NE, SW, NW) con nombres completos. Se detectaron valores atipicos: bmi con 20 registros fuera de rango fisiologico (≤ 0 o ≥ 100 , incluyendo -5 y 999), children con 10 registros fuera de rango razonable (< 0 o > 10 , incluyendo -1, 15 y 99).

3. Decisiones de limpieza y preparacion

Se elimino la columna indice sobrante (Unnamed: 0). Las variables categoricas se estandarizaron a minusculas y las siglas regionales se mapearon a nombres completos (SE->southeast, NE->northeast, SW->southwest, NW->northwest). Los valores atipicos de bmi y children se convirtieron a NaN. La imputacion se realizo con la mediana: age (102 nulos), bmi (70 nulos: 50 originales + 20 outliers), children (10 nulos por outliers). Resultado: 1,363 filas x 7 columnas, 0 nulos, 0 duplicados. Dataset original preservado intacto en data/raw/.

4. Hallazgos del analisis exploratorio

- Distribucion: Asimetrica (skew=1.51). Media=\$13,256 vs Mediana=\$9,361.

- Tabla

5. PCA (Reduccion de dimensionalidad)

Se aplico PCA con StandardScaler sobre 9 variables (age, bmi, children, charges, smoker, sex, y 3 regiones one-hot). PC1 captura el eje de costo/riesgo, dominado por charges, smoker y age, confirmando los hallazgos del EDA. PC2 captura variabilidad demografica y de composicion corporal (bmi, sex, region).

6. Conclusiones y limitaciones

Conclusiones: (1) El tabaquismo es el factor dominante: fumadores pagan mas del triple que no fumadores. (2) La edad es un factor secundario relevante, con efecto amplificado en fumadores. (3) El IMC tiene un efecto menor. (4) Sexo, region y numero de hijos no son determinantes. (5) El PCA confirma que los datos pueden reducirse a menos dimensiones.

Limitaciones: Calidad de datos originales (152 nulos imputados), alcance limitado de variables (sin condiciones medicas preexistentes ni nivel socioeconomico), naturaleza observacional del analisis (correlacional, no causal), y posible sesgo por imputacion con mediana en age y bmi.

Enlaces

Repositorio: <https://github.com/Jav-mol/Mineria-de-datos>

Streamlit: <https://mineria-de-datos.streamlit.app/>