

Proyecto Integrador - Minería de Datos I

Análisis de Factores de Costo en Seguros Médicos

Modulo 3: Modelar y Comunicar | Javier Molina - Federico Claramunt

1. Contexto y objetivo

Este proyecto analiza los factores que influyen en el costo del seguro médico utilizando un dataset de 1,363 asegurados con 7 variables. El objetivo es identificar los principales determinantes del costo mediante EDA, PCA y visualización interactiva con Streamlit.

2. Dataset y calidad inicial

El dataset original contenía 152 valores nulos (102 en age, 50 en bmi) y múltiples inconsistencias en variables categóricas. Se detectaron valores atípicos: bmi con 20 registros fuera de rango fisiológico, children con 10 registros fuera de rango razonable.

3. Decisiones de limpieza y preparación

Se estandarizaron categóricas a minúsculas y siglas regionales a nombres completos. Los valores atípicos se convirtieron a NaN. La imputación se realizó con la mediana: age (102 nulos), bmi (70 nulos), children (10 nulos). Resultado: 1,363 filas x 7 columnas, 0 nulos, 0 duplicados.

4. Hallazgos del análisis exploratorio

- Tabaquismo: Fumadores pagan 3.2x más (corr=0.79). Factor más determinante.

- Edad

5. PCA (Reducción de dimensionalidad)

Se aplicó PCA con StandardScaler sobre 9 variables. PC1 captura el eje de costo/riesgo (charges, smoker, age). PC2 captura variabilidad demográfica (bmi, sex, region). Confirma hallazgos del EDA.

6. Conclusiones y limitaciones

Conclusiones: (1) El tabaquismo es el factor dominante. (2) La edad es un factor secundario con efecto amplificado en fumadores. (3) IMC, sexo, región e hijos no son determinantes. (4) El PCA confirma que los datos pueden reducirse a menos dimensiones.

Limitaciones: Calidad de datos originales (152 nulos imputados), alcance limitado de variables, naturaleza observacional del análisis, y posible sesgo por imputación con mediana.

Enlaces

Repositorio: <https://github.com/Jav-mol/Mineria-de-datos>

Streamlit: <https://mineria-de-datos.streamlit.app/>